【数据预处理模块】

2024 MCM/ICM Problem B: Sustainable Tourism

摘要

本模块依据 B 题翻译与题目资料整理，用于支撑论文“数据预处理”部分。数据口径统一采用赛题给定值：朱诺常住人口约 3 万人、2023 年邮轮旅客 160 万人、旅游收入 3.75 亿美元、最繁忙日游客 2 万人、港口物理可停靠 7 艘、政策上限 5 艘/日、邮轮季 4—10 月、冰川退缩约 8 个足球场。参考 PDF 中的 167 万乘客、4.9 亿美元总支出等仅作为校准字段（加 `ref_` 前缀），不参与主模型计算。离散决策总原则：将措施选择、项目投资、区域限流等设为 0-1 变量，连续变量进行标准化处理。

1 题目提供的数据与规则

数据/规则类型	具体内容（含单位）	建模用途
离散数值数据	游客量（160 万人/年）；日峰值（2 万人/日）；收入（3.75 亿美元）；常住人口（3 万人）；物理泊位（7 艘）；政策上限（5 艘/日）	用于构建基础模型、目标函数校准及硬约束（容量上限）。
规则数据	邮轮季（4—10 月）；冰川退缩（8 个足球场）；支出方向（生态、基建、社区）	场景限制（季节性）；生态约束阈值；预算分配约束条件。
地理/网络数据	朱诺各区域（市中心、冰川、观鲸等）；交通路线距离；区域容量等级	用于热门-冷门空间均衡（网络流与选址-分配模型）。
优先级数据	目标权重（收入、环境、社会、基建）；软约束优先级	确定多目标优化中的权重系数；决定硬约束冲突时的取舍规则。
调查离散数据	居民态度：31% 正面、11% 负面、46% 双面、1% 无影响；管理不足 56%	转化为社会接受度软约束或罚函数项。

2 预处理方案

2.1 缺失值处理

针对离散数据特性，严格避免对 0-1 变量直接取均值：

- **合理假设填充（基于场景规则）**：对未实施的措施 m_j、未选中的项目 y_k、未启用的限流区域 z_i，默认填充为 0。这符合政策规则“未实施 =0”的逻辑。
- **均值/中位数填充（数值型参数）**：对连续型参数（游客量、收入、税率等），采用中位数填充，抵抗潜在异常值。例如：S02 情景中缺失的税率，用全表中位数 0.11 进行填补。
- **邻域插值（地理数据）**：对区域游客量 x_i，采用相邻区域均值插值，并施加总量守恒约束 $\sum_i x_i = x$，确保插值后总游客量不发生变化。

2.2 异常值与冲突规则

采用“统计法（IQR）”与“逻辑校验法”结合的方式：

- **统计检测**：对连续字段采用 IQR（四分位距）缩尾。如发现某支出比例过高，将触发标记并截断至 $Q3 + 1.5 \times IQR$。
- **逻辑校验与修正**：
  - **比例约束**：若 $\delta_I + \delta_E + \delta_C > \delta_{total}$，按比例自动缩放，保证支出不超总预算。
  - **物理与政策冲突**：若政策上限（如 8 艘）超过物理容量（7 艘），强制将政策上限修正为物理容量 7 艘，并留下 `berth_rule_flag = 1` 的修正记录。
  - **季节规则**：若起止月份冲突，强制覆盖为 4—10 月。

2.3 转换处理

多目标优化中不同量纲（如百万级游客量与小数级税率）无法直接相加，故进行标准化处理，保留原始列，并生成标准化列（后缀 `_z` 和 `_minmax`）。

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad \text{(Z-score 标准化)} \tag{1}$$

$$x'_{ij} = \frac{x_{ij} - \min_i x_{ij}}{\max_i x_{ij} - \min_i x_{ij}} \quad \text{(Min-Max 归一化)} \tag{2}$$

网络节点构建：将区域作为网络节点，节点之间的边权 $w_{ij} = 0.6\times$旅行时间归一化$+0.4\times$容量倒数归一化，用于空间均衡模型的网络流分析。

3 数据/规则补充

补充类型	需补充内容	获取途径与合理假设
必须补充	需求弹性区间、环境成本系数、项目边际效率 η、目标权重	参考 B01/B02 及朱诺旅游委员会公开报告。无法获取时，基于场景逻辑假设：需求弹性取 $[-0.2, -0.8]$，η 取 0.5—0.9 三档。所有假设记录在 `source` 字段中。
可选补充	参考 PDF 的 167 万乘客、3850 就业、优先措施比例	作为校准字段，加 `ref_` 前缀，主要用于背景介绍与情景对比。

4 代码与可视化

4.1 本地路径与执行提示

Python 代码（`preprocess.py`）中包含醒目的路径变量，请根据您的本地环境进行替换：

```
# ==================== 本地路径配置 ====================
# 原始数据上传路径：支持 .xlsx / .csv
RAW_DATA_PATH = r"D:\juno_project\data\juno_raw.xlsx"
# 预处理输出路径：CSV、MAT、图片保存在此
OUTPUT_DIR = r"D:\juno_project\preprocessed"
# ======================================================
```

4.2 可视化分析

代码内置了美观性较强的高质量可视化模块（输出 300 DPI 图像），用于直观展示预处理前后的数据形态，包括：

1. **缺失值热力图**：直观展示缺失值的分布，并验证中位数填充的有效性。
2. **异常值箱线图**：使用 IQR 方法识别连续变量的极端离群点。
3. **标准化前后对比图**：展示 Z-score 与 Min-Max 处理后的数据分布变化，证明消除了量纲影响。
4. **0-1 措施采用图**：直观展现离散决策变量的设置状态。
5. **热点-冷点区域游客量对比图**：验证总量守恒及空间分流优化的效果。

5 数据获取与验证

5.1 处理后数据展示（前 10 行与后 5 行）

5.2 虚拟下载链接

预处理代码运行完毕后，会在 `OUTPUT_DIR` 目录下生成以下文件：

- `juno_main_preprocessed.csv` (主数据表，约 12 KB)

表 3: 预处理后主表（juno_main_preprocessed.csv）局部展示

scenario_id	tourists_10k	revenue_100m	tax_rate	delta_I	delta_E	delta_C	ratio_sum_flag	berth_rule_flag
S00_baseline	160.0	3.75	0.110	0.30	0.30	0.20	0	0
S01_low_tour	157.5	3.68	0.110	0.28	0.32	0.20	0	0
S02_high_tour	161.5	3.78	0.110	0.32	0.28	0.20	0	0
S03_strict_eco	160.0	3.75	0.120	0.23	0.38	0.17	1	0
S04_loose_eco	160.0	3.75	0.100	0.35	0.22	0.22	0	0
S05_high_tax	160.0	3.75	0.135	0.26	0.36	0.17	1	0
S06_low_tax	160.0	3.75	0.095	0.30	0.30	0.20	0	0
S07_strict_cap	157.5	3.68	0.120	0.31	0.29	0.18	1	1
S08_loose_cap	161.5	3.78	0.110	0.30	0.28	0.22	0	0
S09_community	160.0	3.75	0.110	0.25	0.25	0.22	0	0
S10_infra	160.0	3.75	0.110	0.35	0.20	0.20	0	0
S11_ecology	160.0	3.75	0.110	0.22	0.38	0.19	1	0
S12_balanced	158.0	3.70	0.120	0.30	0.30	0.20	0	0
S13_perturbed	161.5	3.78	0.130	0.28	0.30	0.22	0	0
S14_conserv	157.5	3.68	0.100	0.28	0.33	0.17	1	0

- `juno_measures_binary.csv` (0-1 措施表，约 3 KB)
- `juno_projects_budget.csv` (项目预算表，约 4 KB)
- `juno_regions_balanced.csv` (空间均衡数据表，约 2 KB)
- `juno_region_edges.csv` (区域网络边表，约 2 KB)
- `juno_preprocessed.mat` (MATLAB 支持的全部数据打包，约 28 KB)
- `figures/` 文件夹（包含 5 张 300dpi 可视化图表）

5.3 Python / MATLAB 保存方法

- **Python 保存**:代码已使用 `to_csv(..., encoding="utf-8-sig")` 保存 CSV,使用 `scipy.io.savemat` 保存 MAT 格式。学生只需修改 `OUTPUT_DIR` 变量即可指定本地输出路径。
- **MATLAB 加载**:直接使用 `T = readtable('juno_main_preprocessed.csv');` 或 `load('juno_preprocessed.` 即可读取全部数据。

5.4 数据完整性验证

代码运行结束时会在终端打印 `Integrity checks`。学生需检查以下核心指标:

- `main_rows`：15 （确认情景未丢失）
- `main_missing_ratio`：0.0 （确认无缺失）
- `ratio_sum_ok`：True （确认比例约束修正成功）
- `policy_le_physical`：True （确认容量规则冲突修复成功）

- region_before_sum / region_after_sum：160.0 （确认空间游客守恒）

6 结论

本模块完成了朱诺可持续旅游 B 题的数据预处理：统一了 160 万游客、3.75 亿美元收入的主口径；将措施、项目、区域等离散决策统一为 0-1 变量；对连续参数完成填充、异常修正、逻辑冲突校验；对多目标量纲完成标准化，并构建了区域网络边权重。输出了 CSV、MAT、报告和高分辨率可视化图片。处理后数据完整合规，可直接进入基础模型建立、支出反哺、敏感性分析、跨目的地迁移与空间均衡的求解。